



TRABAJO PRÁCTICO INTEGRADOR DISEÑO CRÍTICO DE UN SISTEMA RAG CON LANGCHAIN

FCyT UADER

Integrantes: Varrone, Nicolas; García Verdier, Ángela

Docentes: Mg. Díaz, Santiago R. · Anl. López, Joaquín ·
BioIng. Hadad, A.

Índice

Definición del problema.....	3
Construcción del corpus.....	3
Diseño de pipeline.....	4
Evaluación con criterio.....	5
• Preguntas de recuperación directa.....	5
• Preguntas de integración.....	5
• Preguntas límite/trampa.....	6
Comparación de configuraciones.....	7
Análisis de errores.....	9
Reflexión final.....	10
Anexo: Declaración de uso de IA y Bitácora de Desarrollo.....	11

Definición del problema

Se propone como caso de uso, un asistente de soporte técnico en la planta de una empresa ubicada en la ciudad de Paraná, Entre Ríos. Ya que, debido a la extensión de los manuales e instructivos, se presentan dificultades y demoras al solucionar fallas, encender y apagar maquinaria y comprender su funcionamiento. Esto puede llevar a riesgos de seguridad por errores humanos y fallas en la elaboración de artículos.

Los usuarios objetivos son los operadores y supervisores de las distintas áreas de la empresa que hacen uso de la maquinaria antes mencionada. por lo que, el sistema debe poder resolver las siguientes preguntas:

- ¿Cómo encender/apagar la máquina x?
- ¿Qué hacer en caso de fallas en el proceso x?
- ¿Cuál es la temperatura adecuada para el trabajo?

Construcción del corpus

Archivo	Origen	Fecha	Motivo de inclusión
IMAN-008: Mantenimiento Preventivo de Torres de Enfriamiento	Oficina Técnica, Sector Mantenimiento, Planta Paraná.	20/03/2025 (Rev. 2).	Provee protocolos críticos de limpieza, medición de sales ($<1200 \mu\text{S/cm}$ y $<3000 \mu\text{S/cm}$) y dosificación química.
ITER-015: Prueba de Estanqueidad con equipo de presión diferencial	Oficina Técnica, Sector Termotanques, Planta Paraná.	18/09/2024 (Rev. 0).	Detalla el procedimiento técnico para detectar fugas en tanques a una presión de 2.5 kg/cm^2 .
ISOL-002: Instructivo Encendido y Apagado Robots Motoman	Oficina Técnica, Sector Soldadura, Planta Paraná.	04/03/2026 (Rev. 4).	Instrucciones paso a paso para la operación de celdas robóticas, gestión de

			programas "MAESTRO" y resolución de eventos de rutina (falta de gas/alambre).
IMAN-026: Calibración de quemadores del horno de enlozado	Oficina Técnica, Sector Mantenimiento, Planta Paraná.	31/03/2023 (Rev. 0).	Define los rangos de seguridad para gases de combustión (CO estable y O2 al 1.2%) y el uso del equipo PCA3 Bacharach.
IMAN-023: Inspección de Cables de Acero en equipos de Elevación	Oficina Técnica, Sector Mantenimiento, Planta Paraná.	31/03/2023 (Rev. 0).	Establece criterios normativos de seguridad y descarte (diámetros mínimos y rotura de alambres) para prevenir accidentes en elevación de cargas.

Diseño de pipeline

- Carga: se realiza mediante la instrucción **PyPDFLoader**, ya que permite transformar archivos binarios (.pdf) en objetos de tipo Document que LangChain puede manipular.
- Limpieza: se realiza a nivel de ejecución silenciando los logs de librerías ruidosas (**pypdf**, **transformers**) para evitar distracciones en la consola.
- Fragmentación: se utiliza la instrucción **RecursiveCharacterTextSplitter** con un **chunk_size=800** y un **chunk_overlap=150**.
- Embeddings: se utiliza el modelo **all-mpnet-base-v2** de Hugging Face.
- Almacenamiento vectorial: se utiliza **ChromaDB**, persistiendo los datos en la carpeta ./data_db. Esto evita tener que re-indexar los manuales cada vez que se inicia el programa.

- Recuperación: se ejecuta **similarity_search_with_score** con un $k=20$. Luego, se ordena por distancia y elimina duplicados para quedarse con los 10 mejores resultados (TOP_K = 10).
- Generación: se utiliza el modelo Qwen2.5-0.5B-Instruct.

Evaluación con criterio

- *Preguntas de recuperación directa*
 - ¿Cuál es el valor máximo permitido de conductividad para el agua de reposición en las torres de enfriamiento?
Respuesta: Debe ser menor a $1200\ \mu\text{S/cm}$.
 - ¿A qué presión se debe llenar el termotanque para realizar la prueba de estanqueidad?
Respuesta: Se debe llegar a una presión de $2.5\ \text{kg/cm}^2$.
 - ¿En qué sentido se debe girar la perilla para encender los robots Motoman?
Respuesta: Se debe girar en sentido horario.
 - ¿Cuál es el tiempo máximo que debe durar una medición de gases en el horno de enlozado?
Respuesta: La operación no debe prolongarse más de 5 minutos.
 - ¿Cómo se define el criterio de descarte de un cable de acero por variación del diámetro nominal?
Respuesta: Cuando el diámetro real promedio medido en cruz está entre el 94% y 92% del diámetro nominal.
 - ¿Qué instrumento se requiere para medir la concentración de sales en el agua?
Respuesta: Un conductímetro que mida en $\mu\text{S/cm}$.
- *Preguntas de integración*
 - Si se detecta una conductividad mayor a $3000\ \mu\text{S/cm}$ en la pileta de la torre, ¿qué acción física se debe realizar y en qué documento se basa?
Respuesta: Se debe aumentar el caudal de la purga continua abriendo levemente la válvula manual, se obtiene del manual IMÁN 008.
 - ¿Qué procedimiento de limpieza común comparten las rejillas de las torres y el tubo de toma de muestra del horno?
Respuesta: Ambos requieren limpieza para evitar obstrucciones con una herramienta hasta eliminar rastros de hollín.

- ¿Cuáles son los requisitos de registro para una inspección semestral de cables y para una medición diaria de agua?

Respuesta: Para cables, se debe usar la tabla adjunta como registro anual. Para el agua, se debe registrar el dato en el informe correspondiente tras cada medición.

- ¿Qué personal específico debe ser notificado ante fallas en el ablandado de agua y ante daños en la boya de la torre de enfriamiento?

Respuesta: Ante fallas de ablandado (conductividad $>1200\ \mu\text{S/cm}$), avisar al personal de Pintura. Ante daños en la boya, avisar al Supervisor de Mantenimiento.

- ¿Qué significa el led verde encendido en el horno de enlozado y en las mesas de soldadura robótica?

Respuesta: El LED verde en el horno de enlozado y en las mesas de soldadura robóticas indica que el sistema está funcionando correctamente y que todo está listo para iniciar el proceso de enlozado y soldadura. Este estado verde suele ser visualizado cuando el equipo ha sido configurado y preparado adecuadamente antes de su uso.

- De acuerdo a los instructivos de la planta, ¿cuál es el límite de conductividad para el agua de reposición de las torres de enfriamiento y qué tecnología de medición se utiliza para la prueba de estanqueidad de las piezas?

Respuesta: El límite de conductividad para el agua de reposición de las torres de enfriamiento debe ser menor a $1200\ \mu\text{S/cm}$ y en la prueba de estanqueidad de las piezas, se utiliza un conductímetro.

- *Preguntas límite/trampa*

- ¿Qué cantidad de anti-algas se debe agregar a la "Torre 5 - Logística"?

Trampa: El manual IMAN-008 solo lista 4 torres (Fabricación, Inyectoras Sinax x2 y Grossweld). El sistema debe responder que no existe información sobre una "Torre 5".

- ¿Cuál es el procedimiento para cambiar el aceite hidráulico de los robots Motoman?

Trampa: El instructivo ISOL-002 solo cubre encendido, apagado y búsqueda de programas. El sistema debe indicar que el manual no contiene información sobre cambios de aceite.

- Según el manual, ¿se debe limpiar el instrumento de medición con alcohol después de usarlo?

Trampa: El manual indica explícitamente limpiar el instrumento únicamente con agua blanda (de reposición). El alcohol es solo para la jarra de medición.

- ¿Cuál es el número de teléfono del Ing. Rufanacht, Marcelo, para reportar una pérdida en el tanque?

Trampa: Aunque el nombre del ingeniero aparece como aprobador, su número de teléfono no figura en los documentos. El sistema debe limitarse a decir quién aprueba, pero no inventar el contacto.

- Según el manual, ¿qué debe hacer el operador del robot si ocurre un corte de energía eléctrica?

Trampa: El manual ISOL-002 describe paradas de emergencia y procedimientos de rutina, pero no el protocolo ante un apagón general. El sistema debe responder que no hay evidencia suficiente.

- ¿Qué pasos se deben seguir para cargar el programa MAESTRO en el horno de enlozado?

Trampa: El programa "MAESTRO" pertenece exclusivamente al proceso de soldadura de robots. El manual del horno (IMAN-026) no menciona dicho programa. El sistema debe aclarar esta distinción.

Comparación de configuraciones

Modificaciones a realizar: cambiar el tamaño del chunk, overlap, top-k y system prompt.

Modificaciones	1	2	3
Chunk	700	400	700
Overlap	120	50	120
k	7	3	5
System prompt	Eres un Asistente Técnico de Planta de	Eres un Asistente Técnico de Planta de	Si en el contexto aparecen múltiples

	Longvie S.A. Responde utilizando ÚNICAMENTE el contexto proporcionado. Si la información no está en el contexto, indica que no tienes evidencia suficiente.	Longvie S.A. Responde utilizando ÚNICAMENTE el contexto proporcionado. Si la información no está en el contexto, responde únicamente que no tienes evidencia suficiente.	valores numéricos para situaciones similares, comparalos y aclarará la diferencia basándote en las etiquetas del manual (ej: reposición vs. pileta).
Conclusión	Ante la pregunta sobre conductividad, el sistema recupera tanto el dato de agua de reposición ($< 1200 \mu\text{S/cm}$) como el de circuito cerrado ($< 3000 \mu\text{S/cm}$). El modelo de lenguaje se confunde por la similitud semántica y devuelve el valor incorrecto para el caso de uso solicitado.	Se elimina la alucinación numérica. El sistema solo "ve" la respuesta exacta y no tiene fragmentos distractores que lo confundan.	A pesar de incluir instrucciones explícitas para diferenciar entre "agua de reposición" e "información de la pileta", el modelo priorizó el dato de $3000 \mu\text{S/cm}$ sobre el correcto de $1200 \mu\text{S/cm}$. Esto confirma que, en modelos con pocos parámetros, la presencia de datos contradictorios en el contexto recuperado genera una "colisión de atención" donde el modelo es incapaz de seguir

El sistema informó 3000~\mu S/cm para agua de reposición en lugar de 1200~\mu S/cm. Hubo una superposición semántica entre los límites de "reposición" y "pileta" en el manual. Para mitigarlo utilizamos un valor menor en el parámetro k (k=3).

- 2) Al utilizar la tercera modificación del ítem 5) para realizar la consulta anterior, el sistema inventó que el tipo de conductividad era "Arroyo". Esto se debe a la alucinación del modelo LLM ante la incertidumbre de los datos recuperados. Para mitigarlo en el system prompt, se debe, mantener que: Si la información no está en el contexto, indica que no tienes evidencia suficiente.
- 3) Asimismo, con la configuración establecida para la opción anterior, apareció otra falla: el sistema citó la "página 20/03/25", la cual refiere a una fecha, no a un contenido técnico. Para mitigarlo, se debe implementar una limpieza de texto para remover encabezados y pies de página antes del chunking.
- 4) Cuando probamos una de las preguntas trampa (¿Qué pasos se deben seguir para cargar el programa "MAESTRO" en el panel del horno de enlozado?), con la configuración de la primera modificación, el sistema mezcló pasos de robots en el procedimiento del horno de enlozado. Esto quiere decir que hubo contaminación de contexto por metadatos compartidos en los archivos. Para mitigarlo consultamos a Chat GPT que nos recomendó el modelo de Gwen por el 5.1.5.
- 5) Probamos cambiar el valor del parámetro k a 15 y la temperatura a 0.8. Luego, preguntamos: ¿Dosificación para la Torre 5?

Lo que ocurrió, fue una alucinación híbrida de dominios. El sistema primero admite que no tiene evidencia, pero inmediatamente después genera un procedimiento técnico absurdo. Sugiere usar un joystick, desactivar un robot y cambiar tubos de gas para realizar la dosificación de una torre de enfriamiento. Esto se debe a que al tener fragmentos de robots en su memoria de corto plazo, pegó esas instrucciones al nombre de "Torre 5". Para mitigarlo volvimos a la configuración de la modificación 2.

Reflexión final

Podemos concluir que, el aprendizaje más significativo es que el modelo de lenguaje LLM es totalmente dependiente de la calidad de la búsqueda. Por más avanzado que sea el modelo, si el buscador vectorial le entrega fragmentos irrelevantes, el sistema alucinará.

La inteligencia del RAG no reside solo en la generación, sino en la precisión de la recuperación.

Podemos afirmar que los sistemas basados en embeddings no entienden de lógica técnica, sino de distancias matemáticas. Esto quedó demostrado al confundir límites de conductividad de 1200 $\mu\text{S}/\text{cm}$ con 3000 $\mu\text{S}/\text{cm}$ simplemente porque el contexto lingüístico era similar.

También, aprendimos que una base de datos vectorial siempre intentará dar una respuesta. Si se pregunta por un elemento inexistente (como la "Torre 5"), el sistema forzará una respuesta basándose en el fragmento más parecido o en el contexto (memoria a corto plazo).

Por ende, no recomendamos la implementación de un sistema RAG en procesos donde un error numérico (ej. presión de gas o voltajes) pueda derivar en accidentes, no se recomienda confiar en un RAG sin supervisión humana. La posibilidad de "alucinaciones híbridas" (mezclar pasos de robots con hornos) representa un riesgo inaceptable en entornos industriales reales.

Además, si bien el RAG es excelente para encontrar datos específicos, falla al intentar realizar análisis transversales que requieran comparar datos de muchos manuales diferentes o realizar cálculos matemáticos complejos entre páginas.

Y si los parámetros de mantenimiento de Longvie cambiaran diariamente, el costo de re-indexar y la posibilidad de que el sistema recupere manuales obsoletos harían que el RAG fuera menos eficiente que una base de datos relacional tradicional.

Este trabajo demuestra que el RAG es una herramienta poderosa para democratizar el acceso a la información técnica, pero su implementación requiere un diseño riguroso de metadatos y un ajuste fino de los hiperparámetros (k, chunk size). El éxito de un sistema de IA no depende de la "potencia" del modelo, sino del control estricto sobre el contexto que se le permite leer.

Anexo: Declaración de uso de IA y Bitácora de Desarrollo

- Lectura y relectura de consignas del TP.
- Análisis del código de prueba/demostración uso de RAG visto en clases, mediante el uso de Gemini 3 en modo razonamiento, con el prompt: **comenta línea por línea explicando qué hace el código que adjunto.**
- Durante el análisis del código se realizaron las siguientes consultas a Gemini 3:
 - acerca del parámetro "temperatura" con el siguiente prompt: **que es temperature=0.7, # Creatividad?**
 - acerca de los parámetros do_sample y return_full_text: **do_sample=True, return_full_text=False que hacen estos parametros?**

- Posteriormente, se procedió a evaluar con qué documentos se contaban y si hacer uso de RAG era pertinente en cada caso.
- Materiales analizados:
 - Libros de cátedras de la carrera.
 - Acuerdos escolares de convivencia de escuelas secundarias.
 - Diseños curriculares de la provincia.
 - Documentación de cursos Infod.
 - Documentación sobre sugerencias para estudiantes con adaptaciones y flexibilizaciones.
 - Instructivos/manuales de una empresa.
- Finalmente, se eligieron instructivos que describen el funcionamiento, encendido, apagado, usos y fallas en piezas y/o maquinaria de una empresa de Paraná, Entre Ríos. El acceso a esta información fue posible debido a que uno de los integrantes del grupo trabaja allí.
- Luego de seleccionar los documentos, se solicitó a Gemini 3 que armara una tabla con el nombre del archivo, fuente, fecha y el motivo de selección.
- Por consiguiente, siguiendo lo analizado del código de prueba/demostración se elaboró el diseño del pipeline.
- Para el armado de preguntas, se le proporcionó los pdf a la IA con el siguiente prompt: Arma un set de al menos 18 preguntas dividido en: preguntas directas, preguntas de integración y preguntas límite/trampa.
- Se procedió con la modificación del código de prueba/demostración para adaptarlo a los pdf seleccionados. Se le envió el siguiente prompt a la IA: Modifica y adapta el código para que funcione con los 5 pdf que te envió.
- Al intentar ejecutarlo se produjeron los siguientes errores, por no tener instaladas las librerías específicas para el manejo de base de datos Chroma y el motor sentence-transformers que usa langchain-huggingface para procesar los textos:

```

17 # --- IMPORTACIONES DE IA ---
18 from langchain_huggingface import HuggingFaceEmbeddings
19 from langchain_chroma import Chroma

```

Exception has occurred: ModuleNotFoundError ✕
 No module named 'langchain_chroma'

File "C:\Users\angel\OneDrive\Desktop\tpia\tp 1 IA.py", line 19, in <module>
 from langchain_chroma import Chroma
 ModuleNotFoundError: No module named 'langchain_chroma'

```
32 embeddings = HuggingFaceEmbeddings(model_name="all-mpnet-base-v2")

Exception has occurred: ImportError X
Could not import sentence_transformers python package. Please install it with `pip install sentence-transformers`.
ModuleNotFoundError: No module named 'sentence_transformers'

The above exception was the direct cause of the following exception:
```

- Al lograr que compile y dé una respuesta, se observó una alucinación ya que debía responder con el valor 1200 $\mu\text{S}/\text{cm}$

```
=====
RESPUESTA DEL ASISTENTE TÉCNICO LONGVIE
=====
PREGUNTA: ¿Cuál es el valor máximo permitido de conductividad para el agua de reposición en las torres de enfriamiento?
-----
El valor máximo permitido de conductividad para el agua de reposición en las torres de enfriamiento es de 3000  $\mu\text{S}/\text{cm}$ .
=====
Activar Windows
Vea Configuración para activar Windows
```

Para poder solucionarlo se consultó a la IA qué era conveniente modificar, a lo que contestó los chunks ó el top k.

Primero, se procedió a bajar los chunks de 700 a 400 y el overlap de 120 a 100, lo cual no solucionó el problema.

```
# Fragmentación: Chunks de 700 para no perder precisión en los números
text_splitter = RecursiveCharacterTextSplitter(chunk_size=400, chunk_overlap=100)
documents = text_splitter.split_documents([raw_documents])
```

```
=====
RESPUESTA DEL ASISTENTE TÉCNICO LONGVIE
=====
PREGUNTA: ¿Cuál es el valor máximo permitido de conductividad para el agua de reposición en las torres de enfriamiento?
-----
El valor máximo permitido de conductividad para el agua de reposición en las torres de enfriamiento es de 3000  $\mu\text{S}/\text{cm}$ .
=====
Activar Windows
```

Por lo que, se decidió utilizar la segunda opción, reduciendo el valor del parámetro k, de 7 a 3. Esta configuración resolvió el problema.

```
# 4. BÚSQUEDA TÉCNICA (Retrieval)
# -----
# Traemos los 7 fragmentos más relevantes (k=7)
results = vectorstore.similarity_search_with_score(query, k=3)
context_text = "\n\n".join([doc.page_content for doc, score in results])
```

```
=====
RESPUESTA DEL ASISTENTE TÉCNICO LONGVIE
=====
PREGUNTA: ¿Cuál es el valor máximo permitido de conductividad para el agua de reposición en las torres de enfriamiento?
-----
El valor máximo permitido de conductividad para el agua de reposición en las torres de enfriamiento es de 1200  $\mu\text{S}/\text{cm}$ .
=====
Activar Windows
```

- Cuando se corroboraron los parámetros en los que el sistema funciona, se continuó con el ítem 5 de las tareas obligatorias. Para el cual se trabajó sobre la alucinación observada anteriormente.
- Al probar diversos valores en los parámetros sugeridos en el ítem 5, se recopilaban varios fallos que sirvieron para redactar el ítem 6.
- Para poder mitigar los fallos, se recurrió a Gemini 3, pasándole los errores, solicitando que explique cómo solucionarlos paso a paso y probando varias opciones hasta dar con la que solucionaba el problema.
- Por consiguiente, se redactó una breve conclusión y se la enviamos a la IA para que la corrigiera e hiciera lucir más académica.
- Finalmente, se hizo una revisión de lo escrito, se agregó el índice, la carátula y se grabó el vídeo solicitado.